Analisador estatístico em Python

Relatório técnico — Probabilidade e Estatística

Integrantes, em ordem alfabética: Gabriel Chagas; João Vitor Bertolino; Marcelo Moreno; Marlon.

Data: 6 de outubro de 2026. **Entrega prevista no enunciado:** 10 de outubro de 2026.

1. Objetivo e organização

O projeto implementa uma aplicação de linha de comando (CLI) para analisar dados numéricos digitados no terminal ou lidos de um arquivo CSV. O mesmo conjunto de observações é processado em três representações: dados não agrupados, tabela de frequências discretas e distribuição com intervalos de classe. São apresentados moda, média e mediana nas três partes, além das separatrizes exigidas para a distribuição intervalar.

A aplicação utiliza Python 3.10 ou superior e apenas a biblioteca padrão durante sua execução. O pacote statistics fica restrito ao módulo da Parte 1. As Partes 2 e 3 executam diretamente os algoritmos e as fórmulas, sem Pandas, NumPy, SciPy ou chamadas a statistics.

Arquivo ou diretório	Responsabilidade
main.py; estatistica/__main__.py	Pontos de entrada para execução
estatistica/cli.py	Menu, argumentos e apresentação das tabelas
estatistica/entrada.py	Conversão dos dados e leitura de CSV
estatistica/validacao.py	Validação de dados e tabelas
estatistica/nao_agrupados.py	Parte 1: funções nativas de statistics
estatistica/discretos.py	Parte 2: frequências por valor e medidas exatas
estatistica/classes.py	Parte 3: Sturges, classes e interpolação
tests/; dados/; docs/	Testes, exemplos e documentação

O fluxo principal é: entrada → validação → cálculo das três partes → exibição. A separação entre entrada, cálculo e apresentação permite testar as fórmulas independentemente da interface.

2. Entrada e tratamento de erros

A entrada manual aceita números separados por vírgula com ponto decimal, como 1.5,2.5,3. Quando o separador é ponto e vírgula, também é possível usar a vírgula decimal: 1,5;2,5;3. Arquivos CSV podem usar vírgula, ponto e vírgula ou tabulação. O cabeçalho deve ser indicado explicitamente por --cabecalho; --coluna permite selecionar uma coluna pelo nome ou pelo índice, contado a partir de 1.

São rejeitados conjuntos vazios, campos vazios em registros preenchidos, texto em campos numéricos, NaN e infinitos. Os erros de CSV identificam a linha e a coluna quando aplicável. Arquivos inexistentes, ilegíveis ou com estrutura inválida geram mensagens claras. No menu, a entrada inválida permite nova tentativa; EOF e Ctrl+C encerram a execução de forma controlada.

3. Implementação das medidas estatísticas

3.1. Parte 1 — Dados não agrupados

As três medidas são obtidas diretamente por statistics.mean(dados), statistics.median(dados) e statistics.mode(dados), conforme a restrição do enunciado. Em caso de empate na maior frequência, mode retorna o primeiro valor encontrado entre os empatados [1]. A interface explica essa convenção para que ela seja distinguida do resultado multimodal da Parte 2.

3.2. Parte 2 — Tabela discreta

Um dicionário conta as ocorrências de cada valor. As chaves são ordenadas e dão origem às linhas (xi, fi, Fi), nas quais xi é o valor observado, fi sua frequência absoluta e Fi a soma das frequências até a linha atual. As medidas usam exclusivamente essa tabela, sem reconstruir os dados brutos.

Média: $\mu = \Sigma(xi \cdot fi) / n$, com $n = \Sigma fi$. No código, o somatório usa uma escala comum e pesos fi/n, uma forma algebricamente equivalente que evita produtos intermediários excessivamente grandes.

Mediana: para n ímpar, localiza-se a posição $(n + 1)/2$ pela primeira frequência acumulada que a alcança. Para n par, localizam-se as posições $n/2$ e $n/2 + 1$ e calcula-se a média dos dois valores correspondentes.

Moda: identifica-se a maior fi e retornam-se todos os valores que a possuem. Quando todos os valores aparecem apenas uma vez, a aplicação informa que não há moda predominante, embora todos estejam empatados em frequência.

3.3. Parte 3 — Construção das classes

Sturges: $k = \text{ceil}(1 + 3{,}322 \cdot \log10(n))$. O arredondamento para cima é uma decisão explícita da implementação. A amplitude total é A = máximo − mínimo; a amplitude da classe é $h = A/k$.

Os limites são construídos a partir do mínimo com largura h. Os intervalos são fechados à esquerda e abertos à direita: [Li, Ls). O último intervalo inclui o máximo: [Li, Ls]. Cada observação pertence a exatamente uma classe; fi é contado e Fi é acumulado. Classes vazias são preservadas. Não há arredondamento dos limites antes dos cálculos.

Média estimada: $\mu = \Sigma(mi \cdot fi)/n$, com $mi = (Li + Ls)/2$, o ponto médio de cada classe.

Interpolação: $S(p) = L + [(p \cdot n - Fantes)/f] \cdot h$. A busca identifica a primeira classe não vazia cuja frequência acumulada alcança $p \cdot n$. L é seu limite inferior, Fantes é a frequência acumulada anterior e f é a frequência absoluta da classe. A mediana usa p = 0,50; quartis usam 0,25 e 0,75; decis usam 0,20 e 0,70; percentis usam 0,15; 0,22; 0,63 e 0,70.

Moda de Czuber [2]: $Mo = L + [\Delta1/(\Delta1 + \Delta2)] \cdot h$, com $\Delta1 = fm - fant$ e $\Delta2 = fm - fpost$. A classe modal possui a maior frequência; nas extremidades, a frequência da classe vizinha inexistente é convencionada como zero. Empates entre classes modais são informados. Se $\Delta1 + \Delta2 = 0$, não se força uma estimativa única.

Quando todos os dados são iguais, A = 0. Nesse caso, constrói-se uma única classe degenerada [v, v] e todas as medidas retornam v, evitando divisão por zero. Fora desse caso, resultados intervalares são estimativas: o agrupamento perde a posição exata dos dados dentro de cada classe.

4. Exemplo reproduzível e conferência manual

O arquivo dados/exemplo.csv contém 48 observações inteiras. A distribuição discreta usa os valores 0 a 7 com frequências 2, 4, 8, 12, 10, 6, 4 e 2. Portanto, Σxi·fi = 164; média = 164/48 = 3,416667. As posições 24 e 25 pertencem ao valor 3, logo a mediana é 3; a moda também é 3, com frequência 12.

Sturges produz k = ceil(1 + 3,322 · log10(48)) = 7. Como A = 7 − 0 = 7, tem-se h = 1. O máximo 7 pertence à última classe, que também contém o valor 6.

Intervalo	Ponto médio mi	fi	Fi
[0, 1)	0,5	2	2
[1, 2)	1,5	4	6
[2, 3)	2,5	8	14
[3, 4)	3,5	12	26
[4, 5)	4,5	10	36
[5, 6)	5,5	6	42
[6, 7]	6,5	6	48

Média intervalar: Σmi·fi = 186, portanto μ = 186/48 = 3,875000.

Mediana intervalar: a posição n/2 = 24 está na classe [3, 4). Assim, Md = 3 + [(24 − 14)/12] · 1 = 3,833333.

Moda de Czuber: a classe modal é [3, 4); Δ1 = 12 − 8 = 4 e Δ2 = 12 − 10 = 2. Logo, Mo = 3 + [4/(4 + 2)] · 1 = 3,666667.

Separatriz	p	Posição p · n	Valor estimado
Q1	0,25	12,00	2,750000
Q3	0,75	36,00	5,000000
D2	0,20	9,60	2,450000
D7	0,70	33,60	4,760000
P15	0,15	7,20	2,150000
P22	0,22	10,56	2,570000
P63	0,63	30,24	4,424000
P70	0,70	33,60	4,760000

Por exemplo, P63 está na classe [4, 5), cuja frequência anterior é 26 e cuja frequência absoluta é 10: P63 = 4 + [(30,24 − 26)/10] · 1 = 4,424. D7 e P70 coincidem porque representam a mesma proporção acumulada. As diferenças entre as Partes 1/2 e a Parte 3 são esperadas, pois a terceira parte usa pontos médios e interpolação.

5. Execução e validação

Não é necessário instalar pacotes para executar o analisador. Após obter o projeto, abra o terminal na pasta estatistica-python e use Python 3.10 ou superior. Em sistemas nos quais o comando se chama python3, substitua python por python3.

```
python main.py
python -m estatistica --dados "1,2,2,3,4"
python main.py --csv dados/exemplo.csv
python main.py --csv dados/com_cabecalho.csv --cabecalho --coluna valor
python main.py --csv dados/decimais.csv --cabecalho --coluna medida
python -m unittest discover -s tests -v
```

A primeira forma abre o menu interativo. As demais processam os dados diretamente ou executam os testes. A ajuda completa pode ser consultada com python main.py --help. A saída mostra o tamanho da amostra, as três partes, suas tabelas e todas as separatrizes solicitadas.

A verificação automatizada utiliza unittest, da biblioteca padrão. A suíte confere casos com quantidade par e ímpar de observações, valores negativos e decimais, amostras unitárias, dados constantes, modas empatadas, limites entre classes, inclusão do máximo, classes vazias e tabelas de referência calculadas manualmente. Também verifica entradas manuais e CSV, erros de conversão, cabeçalhos, seleção de coluna e a execução da CLI.

Os oráculos matemáticos incluem a tabela de classes [18, 22), [22, 26), [26, 30), [30, 34], com frequências 32, 45, 28 e 15. Seus resultados corretos são média 24,866667; mediana 24,488889; moda de Czuber 23,733333. Esses valores são calculados pelas fórmulas, pois os números ilustrativos de saída no enunciado não correspondem à tabela apresentada.

Resultado da verificação: 60 testes aprovados, sem falhas, em 6 de outubro de 2026. **Ambiente utilizado:** Python 3.12.14. A configuração em .github/workflows/testes.yml prevê executar a suíte no GitHub em outras versões; essa configuração não substitui um resultado observado do serviço.

6. Entrega e limites

O projeto é entregue no repositório privado https://github.com/Morenin888/estatistica-python, com código modular, arquivos CSV, testes, README.md e este relatório em PDF e Markdown. docs/CHECKLIST.md relaciona os requisitos; docs/GITHUB.md orienta execução, atualização e concessão de acesso ao professor antes da entrega.

O programa trabalha com números reais finitos em ponto flutuante. Valores fora da capacidade de representação numérica recebem mensagem de erro. A frequência discreta mantém os valores observados, enquanto as classes fornecem aproximações. A convenção de Sturges, a inclusão do máximo e as regras de empate são documentadas para tornar os resultados reproduzíveis.

Referências

[1] Python Software Foundation. statistics — Funções estatísticas, documentação do Python 3.10. Disponível em: https://docs.python.org/pt-br/3.10/library/statistics.html. Acesso em: 6 out. 2026.

[2] Universidade Federal de Santa Catarina, material didático disponibilizado no Departamento de Informática e Estatística. Moda de King e Moda de Czuber. Disponível em: https://www.inf.ufsc.br/~marcelo/Moda.PDF. Acesso em: 6 out. 2026. Utilizado para a fórmula da moda intervalar e sua interpretação como estimativa.

[3] Trabalho de Estatística em Python. Enunciado fornecido para a disciplina Probabilidade e Estatística, com prazo de entrega em 10 out. 2026. Utilizado para requisitos, separatrizes e formato de entrega.